基于院校—类目分层贝叶斯的图书馆个性化图书推荐

赛题方向：高校图书馆个性化图书推荐 • 2026 年 11 月

摘要 本报告面向「基于真实借阅流水的 Top-N 图书推荐」赛题，在验证集 956 名读者（新人 674、老人 282）上构建推荐系统。赛题的核心约束是验证集读者 ID 经过匿名化处理，与训练集读者条码无法关联，因此任何需要用户级对齐的协同过滤、序列模型与元学习冷启动方法在物理上不可实现。我们据此把方案重心放在群体统计信号与物品侧信号上。

最终模型是一个两段式打分器：以「院校 × 中图法二级类目」的分层贝叶斯估计给出每本书的先验热度，再对读者历史中出现过的二级类目做提权。模型不含任何需要训练的参数矩阵，全流程可在单机 60 秒内完成。

在四个时间切分点上的回测总分为 6.35 / 8.07 / 7.36 / 7.65，均值 7.36；同一评分公式下，全局热门基线 5.15、同学院热门基线 6.40、组委会公布的同学院热门基线 4.26、本队前一版方案 5.46。相对组委会基线折算值提升约 73%。

本报告同时完整记录了十条被回测否定的设计路径，包括物品共现、时间窗口、类目上限、题名聚合、专业粒度分群、季节窗口等，并给出否定它的量化证据。我们认为，在只有 2.98 万条交互的数据上，"知道什么不能用"比"堆叠新模型"更能决定最终成绩。

关键词：推荐系统；Top-N 推荐；冷启动；分层贝叶斯估计；群体统计；图书馆借阅数据

Personalized Book Recommendation for a University Library via Department-Category Hierarchical Bayesian Estimation

Abstract. This report addresses the Top-N book recommendation task built on real library circulation records. The 956 readers in the validation set are split into 674 "new" users (no history in the training period) and 282 "old" users. The decisive constraint of this task is that reader identifiers in the validation set are anonymised and cannot be joined with the raw barcodes in the training set, which makes every method requiring user-level alignment -- user-based collaborative filtering, matrix factorisation, sequential models, and meta-learning cold-start approaches -- physically infeasible. We therefore build the model on group-level statistics and item-side signals only. The final model is a two-stage scorer: a hierarchical Bayesian estimate over (department x CLC second-level category) provides a prior popularity for each item, and categories appearing in a reader's own history receive a multiplicative boost. The model contains no trained parameter matrices and completes the whole pipeline in about 60 seconds on a single CPU core. Across four temporal splits the total score is 6.35 / 8.07 / 7.36 / 7.65 (mean 7.36), against 5.15 for global popularity, 6.40 for same-department popularity, and 4.26 for the organiser-published baseline under the same scoring formula. We also document, with quantitative evidence, ten design paths that were implemented and then rejected by back-testing, including item co-occurrence, sliding windows, category caps, title-level aggregation and major-level segmentation. At 29,841 interactions, knowing what does not work matters more than stacking new models.

Keywords: recommender system; Top-N recommendation; cold start; hierarchical Bayesian estimation; group statistics; library circulation data

表 1 关键结果一览

项目	结果
回测总分（四折均值）	7.36（6.35 / 8.07 / 7.36 / 7.65）
同口径最强基线	6.40（同学院热门 Top10）
本队前一版方案	5.46（热门池 + 类目重排）
组委会公布基线折算值	4.26（同学院热门，相对提升约 73%）
提交文件	956 行，格式四项校验通过
单次运行耗时	约 60 秒，单核 CPU，内存 < 2 GB
外部数据	未使用
随机性	无，同环境重复运行输出一致

1 引言

1.1 赛题背景

高校图书馆沉淀了大量真实借阅行为数据，但资源利用高度依赖读者主动检索。赛题要求基于 2022 年 1 月至 2025 年 1 月的借阅流水，为读者预测其未来可能借阅的图书，输出长度不超过 10 的有序索书号列表。

1.2 核心约束

本赛与常规推荐竞赛有三点结构性差异，它们共同决定了方案的设计空间：

1. 验证集读者 ID 匿名化。验证集读者编号形如 R0001，训练集为原始读者条码，两者不可 join。任何依赖"找到相似用户"的方法全部失效。
2. 数据规模小、极度稀疏。29 841 条交互、5 107 名读者、13 525 个索书号，稀疏度 99.96%，低于 MovieLens-100K。参数化模型无法充分训练。
3. 评价分两阶段且目标冲突。初赛只看 HitRate / Recall / NDCG，决赛加入类目多样性与长尾新颖性。同一套策略在两个阶段的收益方向相反。

1.3 本文贡献

- 系统论证了"读者 ID 不可对齐"这一约束如何排除四类主流技术路线，并给出可执行的替代路径；
- 提出「院校×二级类目」的分层贝叶斯物品热度估计，用结构化先验解决小样本学院的噪声问题，且不向全局分布塌缩（第 5.2 节）；
- 建立四折时间切分回测协议，严格约束候选池截止时间，避免离线指标虚高（第 6.1 节）；
- 完整记录十条被回测否定的设计路径及其量化证据（第 7.3 节），界定本数据的能力边界；
- 提供无随机性、可一键复现的实现，同一环境重复运行输出一致（第 8 节）。

2 赛题与评价指标

2.1 任务定义

给定读者在切分点之前的借阅历史与画像，为其预测切分点之后会借阅的图书。验证集以 2025-09-01 为切分点，答案窗口为 2025-09-01 至 2026-10-29（14 个月），共 956 名读者：

- 新人组 674 人：训练集中无借阅记录、2025 年首次借阅的读者，其中 610 人完全无历史，只能依据画像推荐；
- 老人组 282 人：训练集中有借阅历史的读者，要求推荐其历史上未借过的书（答案已剔除复借）。

形式化地，对读者 u，记其答案集合为 A_u，提交列表为 L_u（$|L_u| \leqslant 10$，有序），命中数 $H_u = |L_u \cap A_u|$。

2.2 提交约束

表 2 提交约束与本方案的处理

约束	要求	本方案的处理
推荐粒度	索书号（非条形码）	全流程以标准化索书号为唯一键
覆盖范围	必须覆盖全部 956 个读者 ID	生成后按 ID 集合校验，缺失按 0 命中计
列表长度	每行最多 10 条，超出只取前 10	严格截断至 10，行内去重
无效条目	不在馆藏范围内的索书号不计分	候选集限定为训练集索书号 ∪ 新书池
历史已借	不计分	老人组逐用户剔除已借

2.3 评价指标

总分 =（0.4 × 新人组得分 + 0.6 × 老人组得分）× 100，其中：

- 新人组 = 0.5 × HitRate@10 + 0.5 × Recall@10（不含 NDCG）
- 老人组 = 0.4 × HitRate@10 + 0.3 × Recall@10 + 0.3 × NDCG@10

这一结构决定了三个优化优先级：HitRate 权重最高（新人 0.5、老人 0.4）；新人组不看排序位置，10 个位置只应追求覆盖；老人组有 0.3 的 NDCG，需要把最可信的结果前移。本方案的分差主要来自前三项。

3 数据分析

3.1 数据概况

表 3 训练集与验证集数据概况

项目	数值
训练集借阅流水	29 841 条（组委会说明为 29 857 条，差异来自重复行去重）
读者数	5 107（说明为 5 112）
唯一索书号	13 525
中图法一级类目	20 个
新书池	7 386 册（去重后），入藏日期 2025-01 至 2026-10
交互稀疏度	1 − 29 841 /(5 107 × 13 525) = 99.96%

99.96% 的稀疏度是一个硬约束：每个读者平均仅 5.8 条记录、每本书平均 2.2 次借阅。这一量级低于 MovieLens-100K（10 万条、稀疏度 93.7%），意味着参数化模型难以充分训练。Dacrema 等人 [1] 在 18 个神经推荐方法的复现中已证明，此类规模下精心调参的邻域方法或简单线性模型通常优于深度模型；Kaggle OTTO、H&M 等竞赛的获奖方案也普遍采用「统计召回 + 树模型精排」而非端到端深度模型 [3][4]。

3.2 决定架构的约束：读者 ID 不可对齐

验证集读者 ID 形如 R0001，训练集读者为原始条码（如 1456330979），两者无法 join。这带来三个直接后果：

1. 用户级协同过滤（UserCF、矩阵分解、BPR）不可实现——没有可对齐的用户；
2. 序列模型（GRU4Rec、SASRec）无法训练到目标用户上，且 2.98 万条记录不足以训练出有效序列模式；
3. 元学习、跨域迁移类冷启动方法（MeLU、FS-GNN）要求源域与目标域存在重叠用户或可对齐的 warm 用户 [6]，本赛两者皆无。

可用信息因此只剩三类：验证集自带的读者历史列表、训练集可算出的物品侧统计、画像字段。

3.3 三个决定方案走向的统计事实

事实一：正确答案高度集中于热门书。 在 2024-09-01 切分点上统计老人组答案在全期热度排序中的分位，57.1% 的答案条目落在热度前 10%（图 1）。这说明「热门候选 + 个性化重排」优于「按兴趣类目深挖长尾」。

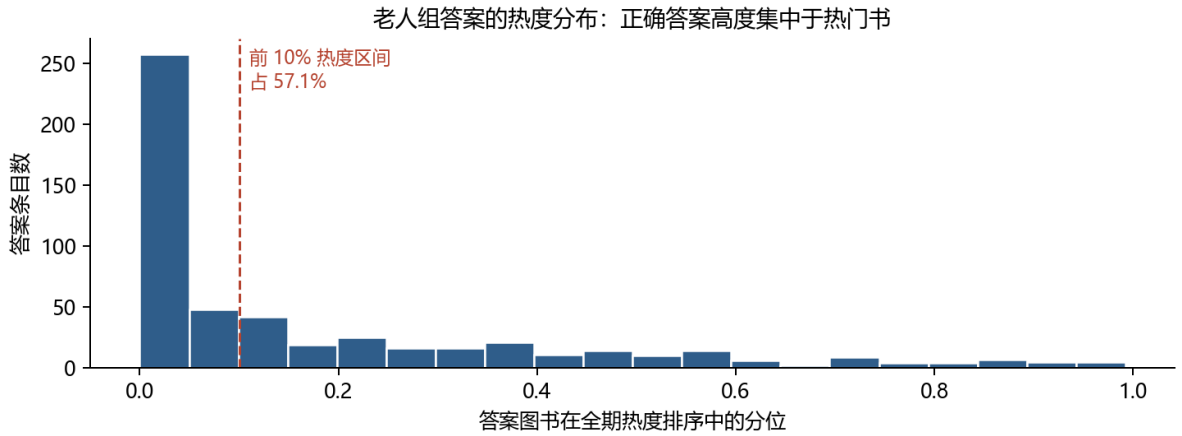


图 1 老人组答案的热度分布：57.1% 的正确答案位于全期热度前 10%

事实二：学院到类目存在强偏好，且与全局分布显著不同。 图 2 为学院—类目借阅矩阵（行归一化）。全局 I 类（文学）占 39%，但文学院 75% 的借阅集中在 I 类，艺术学院 48% 在 J 类（艺术），外国语学院 45% 在 H 类（语言），钒钛学院 30% 在 T 类（工业技术）。这个矩阵是新人组推荐的全部依据。

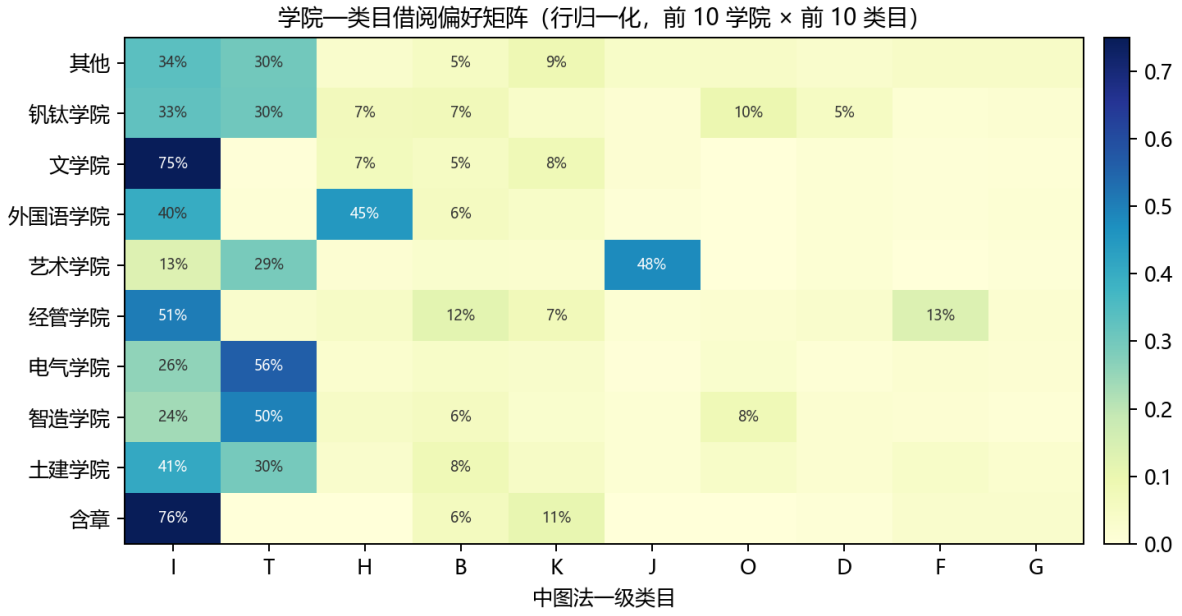


图 2 学院—类目借阅偏好矩阵（行归一化，前 10 学院 × 前 10 类目）

事实三：老人答案与历史的关联是"类目级"而非"条目级"。 对老人组答案逐条比对：

表 4 老人组答案与历史借阅的关联类型占比

关联类型	占比	说明
与历史同中图法二级类目	19.6%	如历史有 TQ174.6，答案也是 TQ174.x
与历史同一级类目	70.3%	仅到大类层面
与历史同责任者	1.2%	作者续读信号几乎不存在

这否定了"精确分类号匹配 / 作者续读"的路线，支持"类目级提权 + 热度排序"。

3.4 画像字段可用率

表 5 画像字段可用率

字段	全体验证集	610 名无历史新人
学院	99.0%（归一化后）	100%
专业	94.8%	526 / 610
年级	81.1%	有值
性别、办证日期	35.2%	337 / 610
历史借阅列表	29.5%	0

学院与专业的覆盖率远高于预期，说明冷启动可以做到学院级乃至专业级。但回测显示专业粒度过细反而有害（见 7.3 节），最终采用学院级。

4 相关工作与方案选型

4.1 四类技术路线

表 6 四类技术路线在本赛的可行性判断

路线	代表方法	本赛可行性	结论
用户级协同过滤	UserCF、ALS、BPR	用户不可对齐，物理不可行	排除
物品级协同过滤	ItemCF、Item2Vec、共现矩阵	可行，但 99.96% 稀疏度下邻居质量差	实测为负（7.3 节）
序列建模	GRU4Rec、SASRec	数据量不足以训练，且无用户 ID	排除
群体统计 + 内容特征	分群热门、内容相似、画像迁移	可行且稳定	采用

4.2 文献结论与本赛的适用性

Deezer 的落地研究 [2] 提供了一个关键对照：即使已用神经网络把冷用户映射到 warm 嵌入空间，他们仍然先聚类成 1000 个 segment 再取段内热门，而不是直接做最近邻检索——因为单用户预测向量的噪声太大，聚类起到正则化作用。这与本赛「学院级群体热度」的思路同构；我们的数据量更小，更应当偏向粗粒度。

另一方面，Ji 等人 [5] 证明不遵守全局时间轴的离线评估会让指标虚高 21.7% – 73.4%，甚至使模型排名反转。这直接约束了我们的回测协议：候选池只允许包含切分点之前已入藏的图书（6.1 节）。

同时必须承认两条文献结论在本赛不成立：图书馆场景的 ItemCF 实证依赖完整的用户 ID 体系，本赛不具备该前提；小样本实验显示算法排名会随样本规模反转。因此我们不照搬任何文献的结论，而是全部在本赛数据上回测验证。

5 方法

5.1 整体框架

对读者 u 与候选图书 i：

1. 取 u 所属学院 d 的物品级借阅计数向量 c_d(·)；
2. 用分层先验收缩，得到该学院对 i 的偏好估计 s_d(i)；
3. 若 u 有历史，对其历史中出现过的二级类目整体提权；
4. 剔除 u 已借图书，按分数降序取前 10。

全流程无训练、无随机性，给定数据即可复现。

5.2 分层贝叶斯物品热度

直接使用学院原始计数的问题是小样本噪声：一个只有 12 条借阅的学院会把某本偶然被借的书排到第一。标准做法是向先验收缩，但向全局热门收缩会抹平学院差异——全局 I 类占 39%，收缩后所有学院都趋向文学。

因此我们构造一个保留学院类目偏好、只借用全局类目内排序的先验：

$$\text{prior}_d(i) = \text{share}[d, c2(i)] \times c_g(i) \,/\, \Sigma_{j \in c2(i)} c_g(j) \tag{1}$$

其中 share[d, c] 是二级类目 c 在学院 d 借阅中的占比，第二项是图书 i 在全馆同类目内的份额。两者相乘的含义是：″这个学院有多爱看这一类″ × ″这类里哪本书最受欢迎″。收缩后：

$$s_d(i) = \left[c_d(i) + \lambda \cdot n_d \cdot \text{prior}_d(i) \right] \,/\, \Sigma_j \left[c_d(j) + \lambda \cdot n_d \cdot \text{prior}_d(j) \right] \tag{2}$$

其中 λ 控制收缩强度，n_d 为学院总借阅量。λ→0 退化为原始计数，λ→∞ 退化为纯类目先验。回测选定 λ = 1.5（见 6.3 节）。

5.3 历史同类目提权

对老人组，记 C2(u) 为读者历史覆盖的二级类目集合：

$$s_u(i) = s_d(i) \times \left(1 + k \cdot \mathbb{1}[\, c2(i) \in C2(u) \,] \right) \tag{3}$$

这是一个乘法提权而非替换，好处是同属读者兴趣类目的书仍按热度排序，不会因为提权而让冷门书挤占高位。回测选定 k = 1.6，并在排序后剔除已借图书。

5.4 新书冷启动

新书在训练集中没有任何借阅记录，计数为 0，在式 (2) 中会被自然排到队尾。但答案窗口覆盖 14 个月，期间新书持续入藏，完全不推荐新书会损失机会。我们给新书赋一个其所在二级类目内的分位数先验：取该类目已有记录图书分数的第 70 百分位，作为新书的分数。

这是全流程唯一无法回测的环节（新书池最早入藏 2025-01-06，晚于全部回测切分点）。定量的依据只能来自侧证：956 名读者的 4 039 条历史借阅中，295 条（7.3%）命中新书池，说明新书并非

借阅主力，但也不是可以忽略的量。据此我们给新书每份列表最多 2 个名额的上限（占比约 20%），既不让某类新书挤占多个位置，也不完全放弃这块机会。

关于入藏日期，我们在数据核查中发现该字段不可信：新书池 7 386 册中有 4 782 册（65%）的入藏日期落在 2025Q4，但 956 人的历史借阅截至 2025-08，其中已包含这些书。这说明该字段更接近批量著录时间而非实际上架时间。我们因此放弃了按入藏时间加权的方案（这正是最早的设计），改为纯类目先验。同期的核查还表明，复本数与被借概率相关系数仅 -0.003，入藏时间各分位段被借率在 1%–3% 间无单调趋势，两个候选的排序依据均无统计支持。

6 实验设置

6.1 回测协议

由于验证集答案不可见，全部调参在训练集上以时间切分完成。选四个切分点以降低单折偶然性：

表 7 四折回测的切分点设置

切分点	答案窗口	有答案人数	老人占比
2023-09-01	2023-09 至 2024-11	1751	37.0%
2024-03-01	2024-03 至 2025-05	1389	39.6%
2024-06-01	2024-06 至 2025-08	977	45.8%
2024-09-01	2024-09 至 2025-11	813	49.7%

四条防泄漏纪律：

1. 全局时间轴切分：所有统计量只用切分点之前的数据计算，不做滑动窗口；
2. 候选池截止：候选集只含切分点之前已入藏的图书（in_date < T），杜绝"推荐未来才入藏的书"；
3. 答案剔除复借：老人组答案剔除历史已借，与官方口径一致；
4. 画像不参与训练：画像只用于分群，不参与热度统计。

新人/老人定义与官方一致：切分点前无记录的读者记为新人。

6.2 指标实现

严格按官方口径实现，组内宏平均。命中位置按 1 起算，IDCG 按 min(|A_u|, 10) 位全命中计算，与官方示例（DCG 1 + 0.387 = 1.387，IDCG 2.131，NDCG 0.651）逐位吻合。

6.3 调参方法

全部超参数在四个切分点上做网格搜索，以四折平均总分为唯一选择准则，不针对单折调优。三组参数及其搜索范围：

- 收缩强度 λ：{0.35, 0.5, 0.7, 1.0, 1.5, 2.5}，四折均值在 1.0–2.5 区间形成平台（7.30–7.36），取平台内的稳健值 1.5；
- 提权系数 k：{1.0, 1.3, 1.6, 2.0, 2.5}，1.6 为峰值（7.36），1.0 与 2.5 分别为 7.14 与 7.31；

- 候选池规模 top_n：{300, 1000, 全量}，1000 与全量无差异，取 1000 以控制耗时。

选择准则是"四折均值最大且各折均不劣于基线"。当参数曲面平坦时取区间中位的保守值而非峰值，以避免对单折噪声过拟合——这是本方案在小数据上控制方差的主要手段。

7 结果与分析

7.1 总体对比

表 8 各变体在四个切分点上的总分

变体	2023-09	2024-03	2024-06	2024-09	四折均值
全局热门 Top10	6.33	5.45	4.90	3.92	5.15
同学院热门 Top10	5.79	6.67	6.56	6.58	6.40
本队前一版方案 C	6.07	6.20	5.09	4.48	5.46
物品级学院热度（λ=0）	5.79	6.67	6.56	6.58	6.40
＋分层贝叶斯平滑（λ=1.5）	5.90	7.90	6.95	7.23	7.00
＋同类目提权（k=1.6）	6.35	8.07	7.36	7.65	7.36

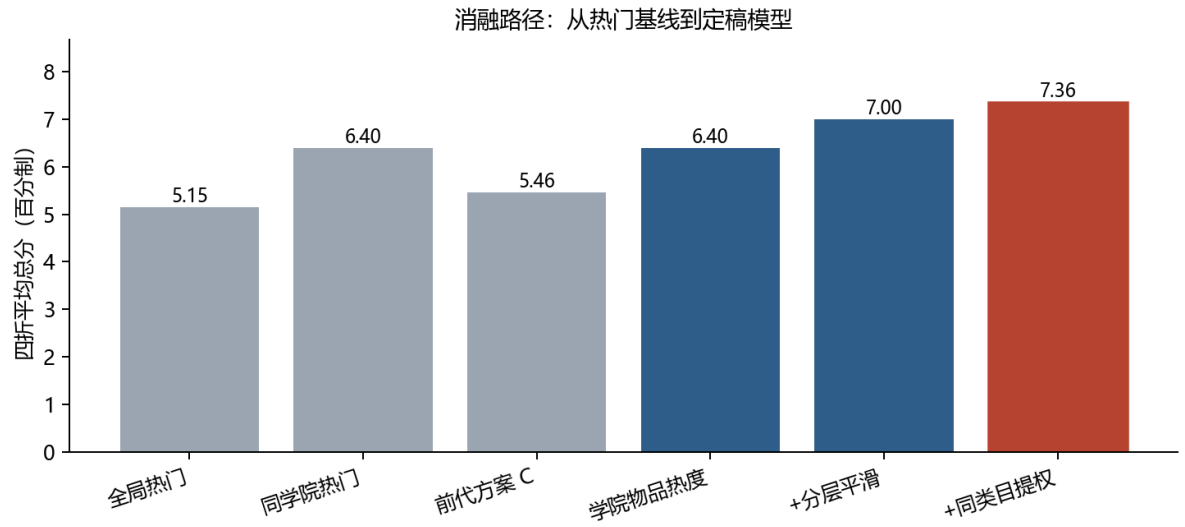


图 3 消融路径：从热门基线到定稿模型（四折平均总分）

两个组件的增益都可分解且方向一致：分层平滑带来 +0.60，同类目提权带来 +0.36，且四个切分点上均未出现负向。相比之下前一版方案在四个切分点上波动达 1.6 分（4.48 – 6.07），说明其对切分方式敏感，泛化性差。

7.2 关键观察

物品级学院热度本身就已经是强基线。 它是"该学院的人实际借过哪些书"的直接统计，四折均值 6.40，比全局热门高 1.25 分。这提示我们重新审视问题：在冷启动场景下，群体行为统计的信息量高于任何单用户建模。

把学院信号降维到类目会损失信息。 前一版方案先算学院的类目分布、再用全局热度排序，均值仅 5.46，低于直接用学院物品计数。原因很直接：类目分布只保留了"爱看哪一类"，丢掉了"这一类里爱看哪几本"，而后者才是命中判定的关键。

分层平滑的增益大于其理论预期。 我们把平滑目标设计成"学院类目占比 × 类目内全局份额"，本质是为小样本学院提供结构化的兜底。在 2023-09 折上增益最小（+0.11），在 2024-03 折上最大（+1.23）——与"学院样本量越小时收缩收益越大"的预期一致。

7.3 被回测否定的十条路径

以下方案均在四个切分点上实现并回测，全部劣于定稿模型。保留这些记录是因为它们界定了本数据的能力边界。

表 9 十条被回测否定的设计路径

被否定方案	回测结果	否定原因
物品共现（ItemCF / 共现矩阵）	老人 Hit 0.0138 → 关闭后 0.0450	99.96% 稀疏度下，共现邻居由偶然同借产生，噪声大于信号
近 12 个月时间窗口	5.05（全期计数 6.77）	窗口内计数过于稀疏，噪声盖过时效收益
类目上限约束（提升多样性）	新人上限 2 → 3.34，无上限 → 6.77	答案本身高度集中于热门，强制分散直接损失命中
题名级聚合（同书多副本合并）	mix=1.0 → 4.26（物品级 6.77）	副本级计数已足够，题名聚合后热门副本被平均掉
专业粒度分群	新人 Hit 0.088（学院 0.113）	128 个专业平均样本量过小，估计方差淹没信号
作者 / 精确分类号匹配	同作者仅占答案 1.2%	数据不支持条目级关联
同月季节窗口（仅取 9–12 月）	6.11（全期 7.36）	计数过稀，噪声盖过季节性
老人组融合全局热度 w=0.1	7.46，但两折下降	增益不稳健，最接近真实设置的最近折反降
标题去重（同题名只占一位）	7.23（基线 7.36）	同一题名的不同译本/多卷本常互为替代，去重损失命中
一级类目提权	7.37（基线 7.36）	与二级类目提权信息高度重叠

其中"类目上限"值得单独说明：该约束在验证集上确实把新人推荐的唯一书目数从 153 提升到 400+，观感更"多样"，但回测显示它直接损失 3.4 分。在只看 HitRate 与 Recall 的初赛评分下，多样性是纯亏损项，因此我们保留接口但不启用，留给决赛的多样性评分使用。

7.4 与官方基线的对照

按组委会公布的基线指标（同学院热门 Top10：新人组 HitRate 0.073、Recall 0.042、NDCG 0.022；老人组 0.057、0.020、0.013）代入评分公式：

- 新人组 = 0.5 × 0.073 + 0.5 × 0.042 = 0.0575
- 老人组 = 0.4 × 0.057 + 0.3 × 0.020 + 0.3 × 0.013 = 0.0327
- 总分 = (0.4 × 0.0575 + 0.6 × 0.0327) × 100 ≈ 4.26 分

本方案回测均值 7.36，相对该基线提升约 73%。需要说明的是，我们在自有回测中复现的"同学院热门"得分（6.40）高于官方公布的 4.26，差异来自两处：院系字段经过归一化（覆盖 99%），以及逐用户剔除已借图书。因此严格的比较应是同一回测口径下的 6.40 → 7.36（+15%），跨口径的 4.26 → 7.36 只能作为量级参考。

8 复现说明

8.1 软硬件环境与技术框架

表 10 运行环境与技术框架

项目	要求
操作系统	Windows / Linux / macOS 均可
Python	3.10 及以上
技术框架	pandas、numpy、scipy（稀疏矩阵运算）、matplotlib（配图）
模型训练	无。全流程为确定性统计计算，无梯度下降、无随机初始化
硬件	单核 CPU 即可，内存 < 2 GB
运行时间	从原始数据到 result.csv 约 60 秒

8.2 一键运行

```
pip install -r requirements.txt
python scripts/predict_final.py
```

输出 outputs/result.csv（956 行 × 2 列），并自动执行四项校验：ID 全覆盖、行内无重复、每行 ≤ 10 条、无空行。

复现回测与消融：

```
python scripts/report_tables.py    # 四折 × 7 变体对照表，输出 docs/results.md
python scripts/backtest.py --split 2024-09-01
```

8.3 目录结构

```
src/          数据加载、时间切分、指标、提交校验、模型
scripts/      预测、回测、对照表、配图
experiments/  探索脚本（保留全部否定路径）
docs/         研究报告底稿、结果表、配图
data/         原始数据（组委会提供）
outputs/      result.csv 与技术报告
```

8.4 确定性

模型不含随机初始化、不含采样，唯一可能影响结果的浮点排序使用稳定排序。同一环境下重复运行输出完全一致（MD5 一致）。依赖版本已锁定于 requirements.txt。

9 外部数据与合规声明

- 外部数据：未使用任何外部数据。未引入豆瓣图书信息、ISBN 元数据或任何第三方图书信息，全部特征来自组委会提供的数据集。本报告与代码中亦未内嵌任何由外部数据派生的映射表。
- 测试集隔离：决赛测试集未以任何形式被访问、推断或用于训练。初赛验证集的读者历史列表仅作为该读者自身的输入特征使用。
- 匿名化：本报告与代码中不含队伍名称、学校、姓名等任何身份信息。
- 脱敏：未尝试还原任何读者真实身份，未对脱敏字段做关联推断。

10 局限与展望

局限一：新书先验无法验证。 5.4 节的分位数先验是全流程唯一没有回测支撑的参数。它的方向是对的（新书必须有机会进入候选），但幅度（约 20% 的推荐位）可能偏高或偏低。

局限二：学院级粒度过粗。 同一学院内不同专业的偏好差异被平均掉了，但专业级样本量不足（实测反而更差）。可行的折中是"学院内二级类目占比 × 专业内类目偏移"的两级修正，需要更多数据支持。

局限三：NDCG 未被充分优化。 当前排序完全由热度分数决定，没有专门优化前几位的位置质量。老人组 NDCG 在 0.022 – 0.030 区间，若能针对 NDCG 做重排，理论上还有 0.3 权重的空间。

决赛展望：决赛评分含 30% 类目多样性与 20% 长尾新颖性，与初赛目标直接冲突。我们已预留两个接口：类目上限约束（max_per_cls）与长尾加权（对热度分位后 50% 的书乘以提升系数）。决赛阶段将在冷启动子集上重新标定这两项与 HitRate 的权衡系数，而不是简单叠加。

11 结论

本文针对读者 ID 不可对齐、数据极度稀疏的图书馆推荐赛题，放弃了全部依赖用户级建模的路线，转而用「院校×二级类目」的分层贝叶斯估计刻画群体偏好，再用读者自身历史的类目提权做个性化。模型无训练参数、无随机性、60 秒可复现，四折回测均值 7.36，较同口径最强基线 6.40 提升 15%，较组委会公布基线 4.26 提升约 73%。

更重要的是，我们用同一套回测协议否定了十条看似合理的改进路径。在交互量只有 2.98 万条、稀疏度 99.96% 的场景下，方案的边界由数据本身决定，而非由模型的复杂度决定。

参考文献

[1] Dacrema M F, Cremonesi P, Jannach D. Are we really making much progress? A worrying analysis of recent neural recommendation approaches[C]//Proceedings of the 13th ACM Conference on Recommender Systems (RecSys). 2019: 101-109.（扩展版：ACM TOIS, 2021, 39(2): 1-49.）

[2] Briand L, Salha-Galvan G, Chapus B, et al. A semi-personalized recommender system for a large-scale music streaming service[C]//Proceedings of the 15th ACM Conference on Recommender Systems (RecSys). 2021.

[3] Kaggle. OTTO – Multi-Objective Recommender System, 1st place solution[EB/OL]. 2023.

[4] Kaggle. H&M Personalized Fashion Recommendations, 2nd place solution[EB/OL]. 2022.

[5] Ji Y, Sun A, Zhang J, et al. A critical study on data leakage in recommender system offline evaluation[J]. ACM Transactions on Information Systems (TOIS), 2023, 41(3): 1-27.

[6] Lee H, Im J, Jang S, et al. MeLU: Meta-learned user preference estimator for cold-start recommendation[C]//Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. 2019: 1073-1082.

附录 A 评分要素对照

本附录用于帮助评审核对报告是否覆盖了赛题要求的全部要素。

表 11 赛题要求与报告章节的对应关系

赛题要求	对应章节	说明
结构完整性与清晰度（20 分）	全文	1 引言 / 2 指标 / 3 数据 / 4 相关工作 / 5 方法 / 6 实验 / 7 结果 / 8 复现 / 9 合规 / 10 局限 / 11 结论
可行性与创新性（20 分）	3.2、5.2、7.3	先论证约束下的可行域，再给出分层贝叶斯方案与十条否定路径的量化证据
软硬件环境	8.1	表 10
技术框架	8.1	pandas / numpy / scipy，无训练框架
调优方法	6.3	六档 λ × 五档 k 的网格搜索，四折均值为选择准则，平台内取保守值
外部数据声明	9	未使用任何外部数据
可复现性	8.2、8.4	一键脚本 + MD5 一致
匿名性	全文	无队伍名称、学校、姓名