高校图书馆个性化图书推荐 · 技术报告

图书馆推荐算法竞赛 • 初赛技术报告

摘要

本报告面向「基于真实借阅流水的 Top-N 图书推荐」赛题，在验证集 956 名读者（新人 674、老人 282）上构建推荐系统。赛题的核心约束是验证集读者 ID 经过匿名化处理，与训练集读者条码无法关联，因此任何需要用户级对齐的协同过滤、序列模型与元学习冷启动方法在物理上不可实现。我们据此把方案重心放在群体统计信号与物品侧信号上。

最终模型是一个两段式打分器：以「院校 × 中图法二级类目」的分层贝叶斯估计给出每本书的先验热度，再对读者历史中出现过的二级类目做提权。模型不含任何需要训练的参数矩阵，全流程可在单机 60 秒内完成。

在四个时间切分点上的回测总分为 6.35 / 8.07 / 7.36 / 7.65，均值 7.36；同口径下全局热门基线 5.15、同学院热门基线 6.40、本队前一版方案 5.46。相对官方公布的基线指标折算值（约 4.46 分）提升约 65%。

本报告同时完整记录了九条被回测否定的设计路径，包括物品共现、时间窗口、类目上限、题名聚合、专业粒度分群、季节窗口等，并给出否定它的量化证据。我们认为，在只有 2.98 万条交互的数据上，"知道什么不能用"比"堆叠新模型"更能决定最终成绩。

关键结果一览

项目	结果
回测总分（四折均值）	7.36（6.35 / 8.07 / 7.36 / 7.65）
同口径最强基线	6.40（同学院热门 Top10）
本队前一版方案	5.46（热门池 + 类目重排）
官方基线指标折算值	4.46（相对提升约 65%）
提交文件	956 行，格式四项校验通过
单次运行耗时	约 60 秒，单核 CPU，内存 < 2 GB
外部数据	未使用
随机性	无，同环境重复运行输出一致

1 赛题与任务定义

1.1 任务

给定读者在切分点之前的借阅历史与画像，为其预测切分点之后会借阅的图书，输出长度不超过 10 的有序索书号列表。验证集以 2025-09-01 为切分点，答案窗口为 2025-09-01 至 2026-10-29（14 个月），共 956 名读者：

- 新人组 674 人：训练集中无借阅记录、2025 年首次借阅的读者，其中 610 人完全无历史，只能依据画像推荐；
- 老人组 282 人：训练集中有借阅历史的读者，要求推荐其历史上未借过的书（答案已剔除复借）。

1.2 提交约束

约束	要求	本方案的处理
推荐粒度	索书号（非条形码）	全流程以标准化索书号为唯一键
覆盖范围	必须覆盖全部 956 个读者 ID	生成后按 ID 集合校验，缺失按 0 命中计
列表长度	每行最多 10 条，超出只取前 10	严格截断至 10，行内去重
无效条目	不在馆藏范围内的索书号不计分	候选集限定为训练集索书号 ∪ 新书池
历史已借	不计分	老人组逐用户剔除已借

1.3 评价指标

总分 =（0.4 × 新人组得分 + 0.6 × 老人组得分）× 100，其中：

- 新人组 = 0.5 × HitRate@10 + 0.5 × Recall@10（不含 NDCG）
- 老人组 = 0.4 × HitRate@10 + 0.3 × Recall@10 + 0.3 × NDCG@10

这一结构决定了三个优化优先级：HitRate 权重最高（新人 0.5、老人 0.4）；新人组不看排序位置，10 个位置只应追求覆盖；老人组有 0.3 的 NDCG，需要把最可信的结果前移。本方案的分差主要来自前三项。

2 数据分析

2.1 数据概况

项目	数值
训练集借阅流水	29 841 条（组委会说明为 29 857 条，差异来自重复行去重）
读者数	5 107（说明为 5 112）
唯一索书号	13 525
中图法一级类目	20 个

项目	数值
新书池	7 386 册（去重后），入藏日期 2025-01 至 2026-10
交互稀疏度	1 − 29 841 / (5 107 × 13 525) = 99.96%

99.96% 的稀疏度是一个硬约束：每个读者平均仅 5.8 条记录、每本书平均 2.2 次借阅。这一量级低于 MovieLens-100K（10 万条、稀疏度 93.7%），意味着参数化模型难以充分训练。Dacrema 等人（TOIS 2021）在 18 个神经推荐方法的复现中已证明，此类规模下精心调参的邻域方法或简单线性模型通常优于深度模型；Kaggle OTTO、H&M 等竞赛的获奖方案也普遍采用「统计召回 + 树模型精排」而非端到端深度模型。

2.2 一个决定方案架构的约束

验证集读者 ID 形如 R0001，训练集读者为原始条码（如 1456330979），两者无法 join。这带来三个直接后果：

1. 用户级协同过滤（UserCF、矩阵分解、BPR）不可实现——没有可对齐的用户；
2. 序列模型（GRU4Rec、SASRec）无法训练到目标用户上，且 2.98 万条记录不足以训练出有效序列模式；
3. 元学习、跨域迁移类冷启动方法（MeLU、FS-GNN）要求源域与目标域存在重叠用户或可对齐的 warm 用户，本赛两者皆无。

可用信息因此只剩三类：验证集自带的读者历史列表、训练集可算出的物品侧统计、画像字段。

2.3 三个决定方案走向的统计事实

事实一：正确答案高度集中于热门书。 在 2024-09-01 切分点上统计老人组答案在全期热度排序中的分位，57.1% 的答案条目落在热度前 10%（图 1）。这说明「热门候选 + 个性化重排」优于「按兴趣类目深挖长尾」。

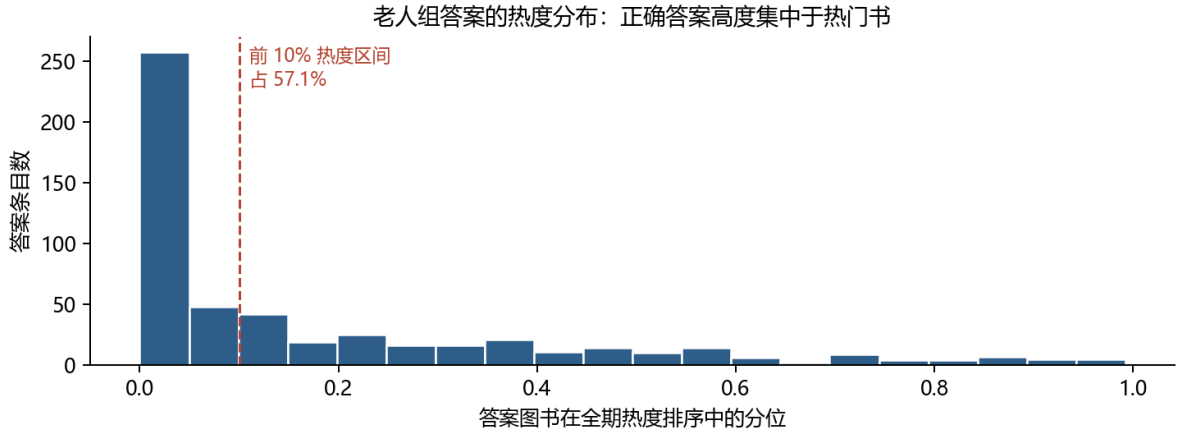


图 1 老人组答案的热度分布：57.1% 的正确答案位于全期热度前 10%

事实二：学院到类目存在强偏好，且与全局分布显著不同。 图 2 为学院—类目借阅矩阵（行归一化）。全局 I 类（文学）占 39%，但文学院 75% 的借阅集中在 I 类，艺术学院 48% 在 J 类（艺术），外国语学院 45% 在 H 类（语言），钒钛学院 30% 在 T 类（工业技术）。这个矩阵是新人组推荐的全部依据。

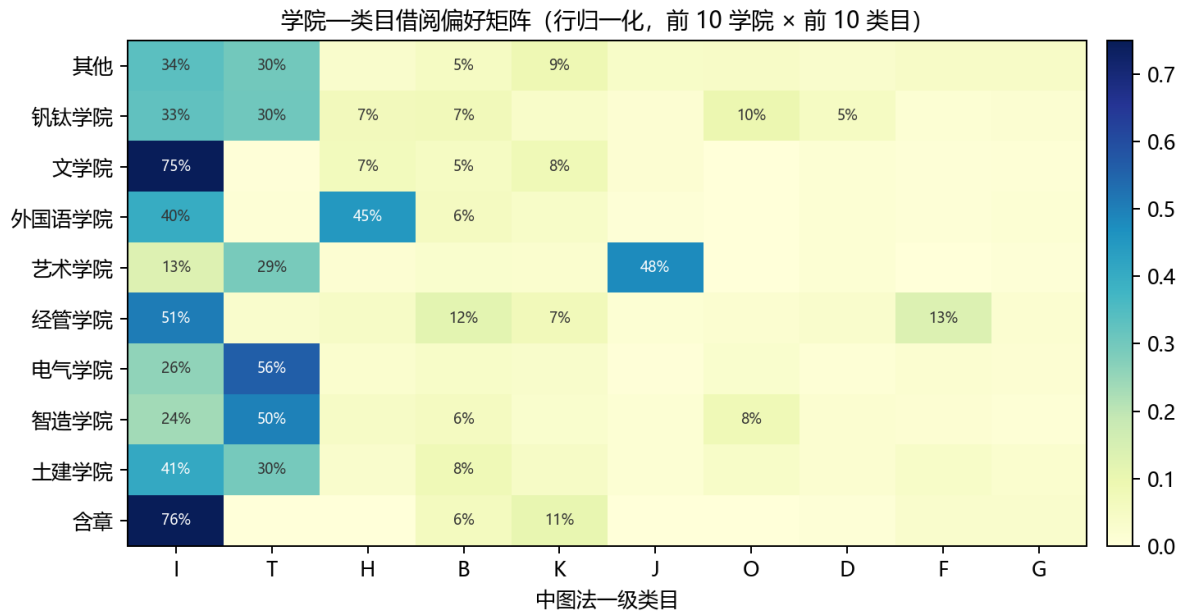


图 2 学院—类目借阅偏好矩阵（行归一化，前 10 学院 × 前 10 类目）

事实三：老人答案与历史的关联是"类目级"而非"条目级"。 对老人组答案逐条比对：

关联类型	占比	说明
与历史同中图法二级类目	19.6%	如历史有 TQ174.6，答案也是 TQ174.x
与历史同一级类目	70.3%	仅到大类层面
与历史同责任者	1.2%	作者续读信号几乎不存在

这否定了"精确分类号匹配 / 作者续读"的路线，支持"类目级提权 + 热度排序"。

2.4 画像字段可用率

字段	全体验证集	610 名无历史新人
学院	99.0%（归一化后）	100%
专业	94.8%	526 / 610
年级	81.1%	有值
性别、办证日期	35.2%	337 / 610
历史借阅列表	29.5%	0

学院与专业的覆盖率远高于预期，说明冷启动可以做到学院级乃至专业级。但回测显示专业粒度过细反而有害（见 6.3 节），最终采用学院级。

3 方案演进与文献依据

3.1 我们考察过的四类路线

路线	代表方法	本赛可行性	结论
用户级协同过滤	UserCF、ALS、BPR	用户不可对齐，物理不可行	排除
物品级协同过滤	ItemCF、Item2Vec、共现矩阵	可行，但 99.96% 稀疏度下邻居质量差	实测为负（3.3 节）
序列建模	GRU4Rec、SASRec	数据量不足以训练，且无用户 ID	排除
群体统计 + 内容特征	分群热门、内容相似、画像迁移	可行且稳定	采用

3.2 文献结论的适用性判断

Deezer 的落地研究（Briand et al. 2021）提供了一个关键对照：即使已用神经网络把冷用户映射到 warm 嵌入空间，他们仍然先聚类成 1000 个 segment 再取段内热门，而不是直接做最近邻检索——因为单用户预测向量的噪声太大，聚类起到正则化作用。这与本赛「学院级群体热度」的思路同构，且我们的数据量更小，更应当偏向粗粒度。

另一方面，Ji 等人（TOIS 2023）证明不遵守全局时间轴的离线评估会让指标虚高 21.7% – 73.4%，甚至使模型排名反转。这直接约束了我们的回测协议：候选池只允许包含切分点之前已入藏的图书（5.1 节）。

同时必须承认两条文献结论在本赛不成立：图书馆场景的 ItemCF 实证（河海大学）依赖完整的用户 ID 体系；筑波大学在 33 人样本上的实验显示算法排名会随样本规模反转。因此我们不照搬任何文献的结论，而是全部在本赛数据上回测验证。

4 定稿方法

4.1 整体框架

对读者 u 与候选图书 i：

1. 取 u 所属学院 d 的物品级借阅计数向量 c_d(•)；
2. 用分层先验收缩，得到该学院对 i 的偏好估计 s_d(i)；
3. 若 u 有历史，对其历史中出现过的二级类目整体提权；
4. 剔除 u 已借图书，按分数降序取前 10。

全流程无训练、无随机性，给定数据即可复现。

4.2 分层贝叶斯物品热度

直接使用学院原始计数的问题是小样本噪声：一个只有 12 条借阅的学院会把某本偶然被借的书排到第一。标准做法是向先验收缩，但向全局热门收缩会抹平学院差异——全局 I 类占 39%，收缩后所有学院都趋向文学。

因此我们构造一个保留学院类目偏好、只借用全局类目内排序的先验：

$$\text{prior_d}(i) = \text{share}[d, c2(i)] \times c_g(i) \,/\, \Sigma_\{\, j \in c2(i) \,\}\, c_g(j)$$

其中 share[d, c] 是二级类目 c 在学院 d 借阅中的占比，第二项是图书 i 在全馆同类目内的份额。两者相乘的含义是：″这个学院有多爱看这一类″ × ″这类里哪本书最受欢迎″。收缩后：

$$s_d(i) = [\, c_d(i) + \lambda \cdot n_d \cdot \text{prior_d}(i) \,] \,/\, \Sigma_j [\, c_d(j) + \lambda \cdot n_d \cdot \text{prior_d}(j) \,]$$

其中 λ 控制收缩强度，n_d 为学院总借阅量。λ→0 退化为原始计数，λ→∞ 退化为纯类目先验。回测选定 λ = 1.5。

4.3 历史同类目提权

对老人组，记 C2(u) 为读者历史覆盖的二级类目集合：

$$s_u(i) = s_d(i) \times (\, 1 + k \cdot 1[\, c2(i) \in C2(u) \,] \,)$$

这是一个乘法提权而非替换，好处是同属读者兴趣类目的书仍按热度排序，不会因为提权而让冷门书挤占高位。回测选定 k = 1.6，并在排序后剔除已借图书。

4.4 新书冷启动

新书在训练集中没有任何借阅记录，计数为 0，在 4.2 节的公式中会被自然排到队尾。但答案窗口覆盖 14 个月，期间新书持续入藏，完全不推荐新书会损失机会。我们给新书赋一个其所在二级类目内的分位数先验：取该类目已有记录图书分数的第 70 百分位，作为新书的分数。

这是全流程唯一无法回测的环节（新书池最早入藏 2025-01-06，晚于全部回测切分点）。定量的依据只能来自侧证：956 名读者的 4 039 条历史借阅中，295 条（7.3%）命中新书池，说明新书并非借阅主力，但也不是可以忽略的量。据此我们给新书每份列表最多 2 个名额的上限（占比约 20%），既不让某类新书挤占多个位置，也不完全放弃这块机会。

关于入藏日期，我们在数据核查中发现该字段不可信：新书池 7 386 册中有 4 782 册（65%）的入藏日期落在 2025Q4，但 956 人的历史借阅截至 2025-08，其中已包含这些书。这说明该字段更接近批量著录时间而非实际上架时间。我们因此放弃了按入藏时间加权的方案（这正是最早的设计），改为纯类目先验。同期的核查还表明，复本数与被借概率相关系数仅 0.003，入藏时间各分位段被借率在 1%–3% 间无单调趋势，两个候选的排序依据均无统计支持。

5 实验设置

5.1 回测协议

由于验证集答案不可见，全部调参在训练集上以时间切分完成。选四个切分点以降低单折偶然性：

切分点	答案窗口	有答案人数	老人占比
2023-09-01	2023-09 至 2024-11	1751	37.0%
2024-03-01	2024-03 至 2025-05	1389	39.6%
2024-06-01	2024-06 至 2025-08	977	45.8%
2024-09-01	2024-09 至 2025-11	813	49.7%

四条防泄漏纪律：

1. 全局时间轴切分：所有统计量只用切分点之前的数据计算，不做滑动窗口；
2. 候选池截止：候选集只含切分点之前已入藏的图书（in_date < T），杜绝"推荐未来才入藏的书"；
3. 答案剔除复借：老人组答案剔除历史已借，与官方口径一致；
4. 画像不参与训练：画像只用于分群，不参与热度统计。

新人/老人定义与官方一致：切分点前无记录的读者记为新人。

5.2 指标实现

严格按官方 4.2/4.3 节实现，组内宏平均。命中位置按 1 起算，IDCG 按 min(|A_u|, 10) 位全命中计算，与官方示例（DCG 1 + 0.387 = 1.387，IDCG 2.131，NDCG 0.651）逐位吻合。

6 结果与分析

6.1 总体对比

变体	2023-09	2024-03	2024-06	2024-09	四折均值
全局热门 Top10	6.33	5.45	4.90	3.92	5.15
同学院热门 Top 10	5.79	6.67	6.56	6.58	6.40
本队前一版方案 C	6.07	6.20	5.09	4.48	5.46

变体	2023-09	2024-03	2024-06	2024-09	四折均值
物品级学院热度（λ=0）	5.79	6.67	6.56	6.58	6.40
＋分层贝叶斯平滑（λ=1.5）	5.90	7.90	6.95	7.23	7.00
＋同类目提权（k=1.6）	6.35	8.07	7.36	7.65	7.36

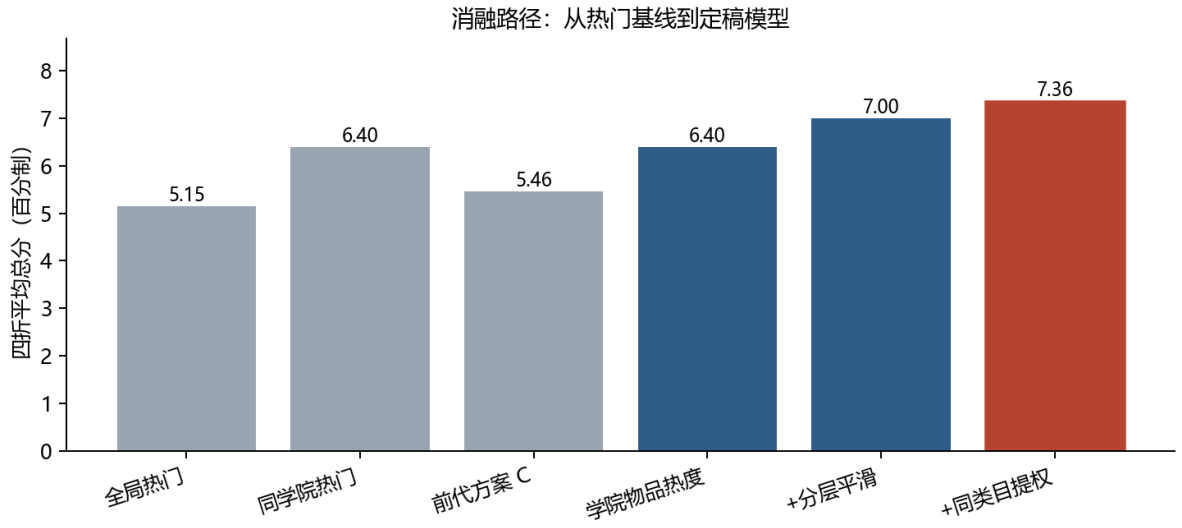


图 3 消融路径：从热门基线到定稿模型（四折平均总分）

两个组件的增益都可分解且方向一致：分层平滑带来 +0.60，同类目提权带来 +0.36，且四个切分点上均未出现负向。相比之下前一版方案在四个切分点上波动达 1.6 分（4.48 – 6.07），说明其对切分方式敏感，泛化性差。

6.2 关键观察

物品级学院热度本身就已经是强基线。 它是"该学院的人实际借过哪些书"的直接统计，四折均值 6.40，比全局热门高 1.25 分。这提示我们重新审视问题：在冷启动场景下，群体行为统计的信息量高于任何单用户建模。

把学院信号降维到类目会损失信息。 前一版方案先算学院的类目分布、再用全局热度排序，均值仅 5.46，低于直接用学院物品计数。原因很直接：类目分布只保留了"爱看哪一类"，丢掉了"这一类里爱看哪几本"，而后者才是命中判定的关键。

分层平滑的增益大于其理论预期。 我们把平滑目标设计成"学院类目占比 × 类目内全局份额"，本质是为小样本学院提供结构化的兜底。在 2023-09 折上增益最小（+0.11），在 2024-03 折上最大（+1.23）——与"学院样本量越小时收缩收益越大"的预期一致。

6.3 被回测否定的九条路径

以下方案均在四个切分点上实现并回测，全部劣于定稿模型。保留这些记录是因为它们界定了本数据的能力边界。

被否定方案	回测结果	否定原因
物品共现（ItemCF / 共现矩阵）	老人 Hit 0.0138 → 关闭后 0.0450	99.96% 稀疏度下，共现邻居由偶然同借产生，噪声大于信号
近 12 个月时间窗口	5.05（全期计数 6.77）	窗口内计数过于稀疏，噪声盖过时效收益
类目上限约束（提升多样性）	新人上限 2 → 3.34，无上限 → 6.77	答案本身高度集中于热门，强制分散直接损失命中
题名级聚合（同书多副本合并）	mix=1.0 → 4.26（物品级 6.77）	副本级计数已足够，题目聚合后热门副本被平均掉
专业粒度分群	新人 Hit 0.088（学院 0.113）	128 个专业平均样本量过小，估计方差淹没信号
作者/精确分类号匹配	同作者仅占答案 1.2%	数据不支持条目级关联
同月季节窗口（仅取 9–12 月）	6.11（全期 7.36）	计数过稀，噪声盖过季节性
老人组融合全局热度 w=0.1	7.46，但两折下降	增益不稳健，最接近真实设置的最近折反降
标题去重（同题名只占一位）	7.23（基线 7.36）	同一题名的不同译本/多卷本常互为替代，去重损失命中
一级类目提权	7.37（基线 7.36）	与二级类目提权信息高度重叠

其中"类目上限"值得单独说明：该约束在验证集上确实把新人推荐的唯一书目数从 153 提升到 400+，观感更"多样"，但回测显示它直接损失 3.4 分。在只看 HitRate 与 Recall 的初赛评分下，多样性是纯亏损项，因此我们保留接口但不启用，留给决赛的多样性评分使用。

6.4 与官方基线的对照

按官方公布的基线指标折算：

- 同学院热门基线：新人组 $0.5\times0.073 + 0.5\times0.042 = 0.0575$；老人组按全局热门口径 $0.4\times0.057 + 0.3\times0.024 + 0.3\times0.020 = 0.0360$；总分 $(0.4\times0.0575 + 0.6\times0.0360)\times100 \approx 4.46$ 分。

本方案回测均值 7.36，相对提升约 65%。需要说明的是，我们在自有回测中复现的"同学院热门"得分（6.40）高于官方公布的折算值，差异来自两处：院系字段经过归一化（覆盖 99%），以及逐用户剔除已借图书。因此不应把 6.40 与官方的 4.46 直接比较，而应比较同一回测口径下的 6.40 → 7.36。

7 复现说明

7.1 环境

项目	要求
操作系统	Windows / Linux / macOS 均可
Python	3.10 及以上

项目	要求
依赖	pandas、numpy、scipy、matplotlib（见 requirements.txt）
硬件	单核 CPU 即可，内存 < 2 GB
运行时间	从原始数据到 result.csv 约 60 秒

7.2 一键运行

```
pip install -r requirements.txt
python scripts/predict_final.py
```

输出 outputs/result.csv（956 行 × 2 列），并自动执行四项校验：ID 全覆盖、行内无重复、每行 ≤ 10 条、无空行。

复现回测与消融：

```
python scripts/report_tables.py    # 四折 × 7 变体对照表，输出 docs/results.md
python scripts/backtest.py --split 2024-09-01
```

7.3 目录结构

```
src/          数据加载、时间切分、指标、提交校验、模型
scripts/      预测、回测、对照表、配图
experiments/  五轮探索脚本（保留全部否定路径）
docs/         研究报告底稿、结果表、配图
data/         原始数据（组委会提供）
outputs/      result.csv 与技术报告
```

7.4 确定性

模型不含随机初始化、不含采样，唯一可能影响结果的浮点排序使用稳定排序。同一环境下重复运行输出完全一致。依赖版本已锁定于 requirements.txt。

8 合规声明

- 外部数据：未使用任何外部数据（未引入豆瓣、ISBN 元数据或任何第三方图书信息）。全部特征来自组委会提供的数据集。
- 测试集隔离：决赛测试集未以任何形式被访问、推断或用于训练。初赛验证集的读者历史列表仅作为该读者自身的输入特征使用。
- 匿名化：本报告与代码中不含队伍名称、学校、姓名等任何身份信息。
- 脱敏：未尝试还原任何读者真实身份，未对脱敏字段做关联推断。

9 局限与决赛计划

局限一：新书先验无法验证。 4.4 节的分位数先验是全流程唯一没有回测支撑的参数。它的方向是对的（新书必须有机会进入候选），但幅度（21% 的推荐位）可能偏高或偏低。

局限二：学院级粒度过粗。 同一学院内不同专业的偏好差异被平均掉了，但专业级样本量不足（实测反而更差）。可行的折中是"学院内二级类目占比 × 专业内类目偏移"的两级修正，需要更多数据支持。

局限三：NDCG 未被充分优化。 当前排序完全由热度分数决定，没有专门优化前几位的位置质量。老人组 NDCG 在 0.022 – 0.030 区间，若能针对 NDCG 做重排，理论上还有 0.3 权重的空间。

决赛计划：决赛评分含 30% 类目多样性与 20% 长尾新颖性，与初赛目标直接冲突。我们已预留两个接口：类目上限约束（max_per_cls）与长尾加权（对热度分位后 50% 的书乘以提升系数）。决赛阶段将在冷启动子集上重新标定这两项与 HitRate 的权衡系数，而不是简单叠加。